


HW2

104070038 陳羿先

My circuit :



My matrix A, b for $Ax = b$:

1. KCL

$$\begin{aligned} I_1 &= I_2 + I_3 \\ I_3 &= I_4 + I_5 \\ I_5 &= I_6 + I_7 \\ I_7 &= I_8 + I_9 \\ I_9 &= I_{10} + I_{11} \end{aligned}$$

2. KVL

$$\begin{aligned} 3I_1 + 3I_2 &= 15 \\ 3I_2 - 4I_3 - 2I_4 &= 0 \\ 2I_4 - 5I_6 - I_5 &= 0 \\ 5I_6 - 2I_7 - 4I_8 &= 0 \\ 4I_8 - 3I_9 - 3I_{10} &= 0 \\ 3I_{10} - 2I_{11} &= 10 \end{aligned}$$

Let $x^T = [I_1, I_2, \dots, I_{11}]$

$AX = b$

$$A = \begin{bmatrix} 1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & -1 & -1 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & -1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & -1 & -1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 & -1 & -1 \\ 3 & 3 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 3 & -4 & -2 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 2 & -1 & -5 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 & -2 & -4 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 4 & -3 & -3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 3 & -2 & 0 \end{bmatrix}_{11 \times 11}$$

$$b = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \\ 0 \\ 15 \\ 0 \\ 0 \\ 0 \\ 0 \\ 10 \end{bmatrix}$$

Discussion :

隨著 $n \times n$ 的矩陣變大，

1. 比較 `np.linalg.det`、`mydet` 的時間

首先，我利用實際執行 3×3 、 5×5 、 11×11 (題目所要求的 circuit)矩陣，來討論隨著 $n \times n$ 矩陣變大，兩種計算 determinant 所需的時間差異。

(1). $n = 3$

a. `np.linalg.det`

```
determinant using numpy:  
-11.000000000000002  
Time to solve determinant using np.linalg.det is  0:00:00.025020  seconds.
```

b. `mydet`

```
determinant using mydet:  
-11  
Time to solve determinant using mydet is  0:00:00.002001  seconds.
```

(2). $n = 5$

a. `np.linalg.det`

```
determinant using numpy:  
-229.99999999999983  
Time to solve determinant using np.linalg.det is  0:00:00.018013  seconds.
```

b. `mydet`

```
determinant using mydet:  
-230  
Time to solve determinant using mydet is  0:00:00.001000  seconds.
```

(3). 如題目要求在 $n = 11$ 時，

a. `np.linalg.det`

```
determinant using numpy:  
-78531.00000000004  
Time to solve determinant using np.linalg.det is  0:00:00.018014  seconds.
```

b. `mydet`

```
determinant using mydet:  
-78531  
Time to solve determinant using mydet is  0:04:06.021025  seconds.
```

我們可以發現，當 n 值較小時，利用 numpy 內建的 `np.linalg.det`、與使用我們自己所寫的 `mydet` 來計算 determinant 所需時間相差不多，但隨著 n 值變大，`mydet` 所需的時間會急速上升，無法像 `np.linalg.det` 一樣仍保持極快的運算速度。

以我所寫的 `mydet(A)` 來說，因為會跑一個從 $i=0$ 到 `range(n)` 的 for 迴圈，而迴圈又會 recursively 的呼叫 `mydet(Mij)` $O(n)$ 次（Minor matrix 從 $(n-1)*(n-1)$ 到 $1*1$ ），因此這個 function 可以寫成：

$$T(n) = n \times T(n-1) + (2n-1)$$

透過演算法的運算，我們最終可得到這樣的推導：

$$\begin{aligned} T(n) &= n \cdot T(n-1) + 2n-1 \\ &= n \cdot (n-1) \cdot T(n-2) + n \cdot (n-1) \\ &= n \cdot ((n-1) \cdot ((n-2) \cdot (\dots) + n-3) + n-2) + n-1 \\ &= 2n-1 + n \cdot (2(n-1)-1) + n \cdot (n-1) \cdot (2(n-2)-1) + \dots + n! \\ &< 2 \cdot n + 2 \cdot n \cdot (n-1) + 2 \cdot n \cdot (n-1) \cdot (n-2) + \dots + 2 \cdot n! + n! \\ &= 2 \cdot (n + n \cdot (n-1) + \dots + n!/2) + 3 \cdot n! \\ &< 2 \cdot (n!/(n-1)! + n!/(n-2)! + \dots + n!/2!) + 3 \cdot n! \end{aligned}$$

又因為：

$$\frac{2 \times n!}{k!} \leq \frac{n!}{(k-1)!} \text{ for all } k \geq 2$$

$$\begin{aligned} &n!/(n-1)! + n!/(n-2)! + n!/(n-3)! + \dots + n!/2! \\ &\leq n!/(n-2)! + n!/(n-2)! + n!/(n-3)! + \dots + n!/2! \\ &\leq n!/(n-3)! + n!/(n-3)! + \dots + n!/2! \\ &\leq n!/(n-4)! + \dots + n!/2! \\ &\leq \dots \\ &\leq n!/2! + n!/2! \\ &\leq n! \end{aligned}$$

$$\text{因此，} T(n) = n \times T(n-1) + (2n-1) = O(n!)$$

Complexity of `mydet` 可以用 $O(n!)$ 來表示，因此當 n 值增大時，計算所需時間上升非常快，無法像 `np.linalg.det` 計算來的迅速。

```
det = 0
for i in range(n):
    # compute minor M(0,i)
    ### you can use np.concatenate((A,B), axis=1) to merge two matrices
    if i==0:
        M = A[1:n,1:n]
    else:
        X = A[1:n,0:i]
        Y = A[1:n,i+1:n]
        M = np.concatenate((X,Y), axis=1)
    # compute cofactor A(0,i) = (-1)^{i} det(M(0,i))
    if i%2==0:
        C = mydet(M)
    else:
        C = -mydet(M)
    det = det + A[0][i] * C
    ### call mydet recursively to compute det(M)
```

2. 比較 `np.linalg.solve`、`mysolve_adj`、`mysolve_cramer` 的時間

(1). $n = 3$

a. `np.linalg.solve`

```
Time to solve Ax=b using np.linalg.solve is 0:00:00.246176 seconds.  
rediduals of Ax=b using np.linalg.solve:  
[[0.00000000e+00]  
 [4.4408921e-16]  
 [4.4408921e-16]]
```

b. `mysolve_adj`

```
Execution Time using adjoint matrix = 0:00:00.000999 seconds.  
  
rediduals of Ax=b using adjoint matrix:  
[[ 0.00000000e+00]  
 [-4.4408921e-16]  
 [ 0.00000000e+00]]
```

c. `mysolve_cramer`

```
Execution Time using Cramer's rule = 0:00:00 seconds.  
  
rediduals of Ax=b using Cramer's rule:  
[[ 1.11022302e-16]  
 [ 0.00000000e+00]  
 [-2.22044605e-16]]
```

(2). $n = 5$

a. `np.linalg.solve`

```
Time to solve Ax=b using np.linalg.solve is 0:00:00.001001 seconds.  
rediduals of Ax=b using np.linalg.solve:  
[[-2.22044605e-16]  
 [ 2.22044605e-16]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]]
```

b. `mysolve_adj`

```
Execution Time using adjoint matrix = 0:00:00.005002 seconds.  
  
rediduals of Ax=b using adjoint matrix:  
[[-2.22044605e-16]  
 [-4.44089210e-16]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]]
```

c. mysolve_cramer

```
Execution Time using Cramer's rule = 0:00:00.004000 seconds.  
  
rediduals of Ax=b using Cramer's rule:  
[[0.00000000e+00]  
 [2.22044605e-16]  
 [0.00000000e+00]  
 [0.00000000e+00]  
 [0.00000000e+00]]
```

(3). 如題目要求在 $n = 11$ 時，

a. np.linalg.solve

```
Time to solve Ax=b using np.linalg.solve is 0:00:00.036025 seconds.  
rediduals of Ax=b using np.linalg.solve:  
[[ 0.00000000e+00]  
 [-1.24900090e-16]  
 [ 1.11022302e-16]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]]
```

b. mysolve_adj

```
Execution Time using adjoint matrix = 0:54:14.173832 seconds.  
  
rediduals of Ax=b using adjoint matrix:  
[[ 2.22044605e-16]  
 [-5.55111512e-17]  
 [-5.55111512e-17]  
 [ 0.00000000e+00]  
 [-4.44089210e-16]  
 [ 0.00000000e+00]  
 [ 8.88178420e-16]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]]
```

c. mysolve_cramer

```
Execution Time using Cramer's rule = 0:52:24.990416 seconds.  
  
rediduals of Ax=b using Cramer's rule:  
[[-2.22044605e-16]  
 [-4.16333634e-17]  
 [ 5.55111512e-17]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]  
 [ 0.00000000e+00]]
```

比較 `np.linalg.solve`、`mysolve_adj`、`mysolve_cramer`，可以發現在 n 值小時 (ex: $n=3$)，三種方法所需時間都差不多 (1 秒內可以計算出)，但隨著 n 值增加，`np.linalg.solve` 的優勢便漸漸顯露，在 $n=5$ 時可以發現其計算時間比 `mysolve_adj`、`mysolve_cramer` 快；在 $n=11$ 時更加明顯，`np.linalg.solve` 仍可維持 1 秒內的計算速度，但 `mysolve_adj`、`mysolve_cramer` 需要的時間都超過了 30 分鐘。

`mysolve_adj` 實作方法：

以 `mysolve_adj` 而言，我利用了雙層 `while` 迴圈來得到 minor matrix M (透過 `np.concatenate()` 合成所需的 elements) 與 inverse matrix of A ： A^{-1} (命名為 `adj`)，而此兩者的關係式為：

$$adj[j][i] = (-1)^{i+j} \times \text{mydet}(M_{ij}) \div \text{mydet}(A)$$

在得到 A^{-1} 後，利用 $x = A^{-1} \cdot b$ ，即可得到解 x 。

因為在雙層迴圈中需要不斷呼叫 `mydet`，因此我認為 complexity 可寫成：

$$O(n!) \times O(n^2) = O(n^2 \times n!)。$$

```
def mysolve_adj(A, b, detA):
    # TODO: 1. solve Ax=b using adjoint matrix (using mydet)
    n = A.shape[0]
    ans = np.empty((n,1))
    # M = inverse matrix of A
    if n == 2:
        adj = [[A[1][1]/detA, -1*A[0][1]/detA],
               [-1*A[1][0]/detA, A[0][0]/detA]]
    else:
        M = np.empty((n-1,n-1))
        adj = np.empty((n,n))
        i = 0
        while i<n:
            j = 0
            while j<n:
                if i==0:
                    X = A[1:n,0:j]
                    Y = A[1:n,j+1:n]
                    M = np.concatenate((X,Y), axis=1)
                elif i<n-1:
                    X = A[0:i,0:j]
                    Y = A[0:i,j+1:n]
                    N = np.concatenate((X,Y), axis=1)
                    U = A[i+1:n,0:j]
                    V = A[i+1:n,j+1:n]
                    P = np.concatenate((U,V), axis=1)
                    M = np.concatenate((N,P), axis=0)
                elif i == n-1:
                    X = A[0:n-1,0:j]
                    Y = A[0:n-1,j+1:n]
                    M = np.concatenate((X,Y), axis=1)
                sign = (-1)**(i+j)
                adj[j][i] = sign * mydet(M) / detA
                j = j + 1
            i = i + 1
        # x = A^-1 * b
        ans = np.dot(adj, b)
    return ans
```

mysolve_cramer 實作方法：

以 mysolve_cramer 而言，我透過 for 迴圈計算解 x 中每個 x_i 需要的 matrix M (把第 i 個 column 用 b 取代，可透過 `np.concatenate()` 來合成所需的 elements)，因此存在以下關係式：

$$x_i = \text{mydet}(M) \div \text{mydet}(A)$$

就可以得到我們需要的解 x 。其 complexity 因為迴圈中也須不斷呼叫 `mydet(A)`，因此也可寫成：

$$O(n!) \times O(n) = O(n! \times n)。$$

總結來說，從 complexity 分析和實際實驗結果兩方面加總來看，計算速度快慢可表示成：

$$\text{np.linalg.solve} > \text{mysolve_cramer} > \text{mysolve_adj}$$

```
def mysolve_cramer(A, b, detA):
    # TODO 2. solve Ax=b using Cramer's rule (using mydet)
    # return ?
    n = A.shape[0]
    ans = np.empty((n,1))
    for i in range(n):
        if i==0:
            X = A[0:n,1:n]
            M = np.concatenate((b,X), axis=1)
            ans[i] = mydet(M)/detA
        else:
            X = A[0:n,0:i]
            Z = np.concatenate((X,b), axis=1)
            Y = A[0:n,i+1:n]
            M = np.concatenate((Z,Y), axis=1)
            ans[i] = mydet(M)/detA
    return ans
```

Residuals 比較：

透過 `np.subtract(np.dot(A, x), b)`，我們將矩陣 A 乘上利用不同方法所解出的 x ，並與 b 相減來得到每種方法解出來的誤差值 $\|A \cdot x - b\|$ 。可以發現，以 $n=11$ 為例，利用 numpy 內建的 `np.linalg.solve` 算出的 residuals 只有兩個 x_i 存在誤差值，且誤差值都落在 10^{-16} 左右，可以說是算得又快又準。

`mysolve_cramer` 的結果也不差，大概有三項 x_i 存在誤差，誤差相減結果也是落在 10^{-16} 左右，雖然速度慢，但是精準度還是很夠。

`mysolve_adj` 的計算結果有大概 5 項 x_i 有誤差，但也都是 10^{-16} 左右，因此我認為我實作的這兩種方法計算出來的結果仍然非常準確，就是輸在了時間，如此更可以瞭解內建 `np.linalg.solve` 的強大。

Bonus :

1. `np.linalg.det`、`np.linalg.solve` 為什麼能算得這麼快?

`np.linalg.det`、`np.linalg.solve` 的運算建立在 LU 分解下，對一個 $n \times n$ 的矩陣 A 來說，我們可以將 A 分解成一個下三角矩陣 L 和一個上三角矩陣 U 的乘積，也就是 $A = LU$ 。因此如果適當的改變 A 的行的順序或列的順序，就可以將 A 做 LU 分解。LU 分解在本質上是 Gaussian Elimination 的一種表達形式，實質上，是將 A 通過運算變成一個上三角矩陣，那麼 A 的 transpose matrix 就是一個單位下三角矩陣，這正是所謂的 Doolittle algorithm。

以我們設計的 11×11 矩陣來說，因為大部分的 $A[i][j]$ 都為 0，因此 A 可以說是一個稀疏矩陣(代表大部分值為 0)，而 LU 分解對於階數很大的稀疏矩陣，存在特別的簡便算法，因為在 A 為稀疏矩陣的情況下，其找出的 L 、 U 也會是稀疏矩陣，理論上來說，此時算法的複雜度約等於非零係數的個數，而不是矩陣的大小階數，這些算法通過運用行、列的交換，使得過程中零係數因為操作而變成非零係數的次數減到最少，因此此時計算不需要完全的跑過 $n \times n$ 的矩陣(也就是如我們所寫跑過雙層迴圈)，而是簡化過的(只計算非零係數的地方)，因此時間相較於我們所設計的 `mysolve_adj`、`mysolve_cramer` 來說，當然簡化許多。

a. `np.linalg.det`

以 determinant 來說，因為 $A = LU$ ，而 determinant of A 可寫成 $\det(A) = \det(L) \times \det(U)$ ，因為 L 、 U 都是 triangle matrix，而 triangle matrix 的 determinant 就是對角線 element 的乘積，也就是

$$\det(A) = \det(L) \times \det(U) = \prod_{i=1}^n l_{ii} \times \prod_{j=1}^n u_{jj}$$

因此，如此計算 determinant 的方式會比直接找出所有 minor matrix 來說迅速許多。

b. `np.linalg.solve`

對於解出 $Ax = b$ 來說，我們利用 LU 分解，寫成 $Ax = LUx = b$ ，要解出 x ，可以進行一下步驟：

(1). 首先，解方程式 $Ly = b$ 得到 y

(2). 然後解方程式 $Ux = y$ 得到 x 。

在兩次的求解中，我們遇到的都是三角矩陣，因此運用向前（向後）替代法就可以簡潔地求解，而不需要用到 Gaussian Elimination，因此也可以達到加速的效果。